

VCIP × MIMIC-III

Pipeline Completo de Implementação

Decisão de Transfusão de Sangue em UTI com Otimização Contrafactual

Objetivo: Reduzir Mortalidade via Sequências Ótimas de Intervenção

Visão Geral do Pipeline

Este documento descreve o pipeline completo — do dado bruto à otimização de sequências de intervenção — para aplicar o VCIP ao problema de decisão de transfusão de hemácias em UTI usando o banco MIMIC-III. O objetivo primário é **reduzir a mortalidade hospitalar** identificando, para cada paciente, o momento e a quantidade ideal de transfusão, considerando seu histórico clínico completo.

Ao contrário de modelos preditivos clássicos ("este paciente vai morrer?"), o VCIP responde a uma pergunta causal: *"dado o histórico deste paciente até agora, qual sequência de decisões de transfusão maximiza a probabilidade de ele atingir um estado clínico-alvo (sobrevivência + estabilidade hemodinâmica)?"*

Mapeamento para o Formalismo VCIP

Sujeito (i): Cada internação em UTI (ICUSTAY_ID)

Covariáveis X_t : Sinais vitais, exames laboratoriais, escores clínicos — medidos ao longo do tempo

Tratamento A_t : Decisão de transfusão (binária: transfundiu/não transfundiu) ou dose (contínua: unidades de CH transfundidas)

Resultado Y_t : Variáveis clínicas proxy (hemoglobina, lactato, PAM) e/ou mortalidade em 28/90 dias

Histórico $\tilde{H}_t$: Toda a trajetória do paciente até o instante t

Alvo Y_{target} : Hemoglobina ≥ 7 g/dL + PAM ≥ 65 mmHg + ausência de choque — ou simplesmente: sobrevivência ao dia 28

Horizonte τ : 4–24h à frente (8 a 288 slots de 5 min)

O pipeline tem **10 etapas** sequenciais, descritas a seguir com detalhes de implementação, decisões técnicas e justificativas clínicas.

ETAPA 1

Acesso e Estrutura do MIMIC-III

Licenciamento, tabelas-chave e arquitetura do banco

1.1 Acesso ao Banco

O MIMIC-III é um banco de dados de acesso controlado hospedado no PhysioNet. O acesso exige: (a) conclusão do curso CITI "Data or Specimens Only Research"; (b) assinatura do Data Use Agreement; (c) aprovação em ~1 semana. Após aprovação, os dados ficam disponíveis via download direto ou via BigQuery (Google Cloud).

Recomendação: Use o BigQuery para exploração inicial — permite queries SQL sem baixar os ~60 GB do banco inteiro. Para treinamento do VCIP, baixe somente as tabelas necessárias.

1.2 Tabelas-Chave para este Projeto

Tabela MIMIC	Conteúdo	Uso neste pipeline
ICUSTAYS	Metadados de cada internação em UTI (datas, ICUSTAY_ID, unidade)	Âncora temporal — definir janela de observação
PATIENTS	Dados demográficos: sexo, data de nascimento, data de óbito	Calcular idade; definir desfecho de mortalidade
ADMISSIONS	Dados de internação hospitalar, diagnósticos ICD	Contexto clínico, diagnóstico de entrada
CHARTEVENTS	Sinais vitais e parâmetros de monitoramento (>330 M linhas)	Principal fonte de covariáveis temporais X_t
LABEVENTS	Resultados de exames laboratoriais (~28 M linhas)	Hemoglobina, lactato, creatinina, coagulograma
INPUTEVENTS_MV	Fluidos e medicações (ventilador Metavision)	Intervenções concorrentes (vasopressores, volume)
OUTPUTEVENTS	Débito urinário, drenos	Balanço hídrico, função renal
PROCEDUREEVENTS_MV	Procedimentos clínicos	Identificar transfusões e outros procedimentos
D_ITEMS	Dicionário de ITEMID: descrição de cada item clínico	Mapear ITEMIDs para variáveis de interesse
D_LABITEMS	Dicionário de exames laboratoriais	Mapear ITEMID de labs para nomes

1.3 Identificação de Transfusões no MIMIC

Transfusões de hemácias (Packed Red Blood Cells — PRBC) no MIMIC ficam predominantemente em `PROCEDUREEVENTS_MV` e `INPUTEVENTS_MV`. Os ITEMIDs relevantes são:

- ITEMID 225168 — Packed Red Blood Cells (Metavision)
- ITEMID 226368 — OR Packed RBC Administered
- ITEMID 227070 — Fresh Frozen Plasma (FFP) — tratamento associado
- Verificar D_ITEMS para variantes locais de nomenclatura por unidade de UTI

Atenção Clínica

Gatilho transfusional padrão: Hb < 7 g/dL em pacientes estáveis; Hb < 8–10 g/dL em cardiopatas. O VCIP deve aprender QUANDO o benefício real supera esse threshold, porque confundimento por indicação é forte: pacientes mais graves recebem mais transfusões.

Estratégia liberal vs. restritiva: Há evidência (TRICC trial) de que estratégias restritivas (transfundir apenas com Hb < 7) não são inferiores a liberais em mortalidade. O VCIP pode capturar nuances individuais que regras populacionais não capturam.

ETAPA 2

Seleção de Coorte e Critérios de Inclusão/Exclusão

Definir a população de estudo com rigor clínico e metodológico

Antes de qualquer pré-processamento, é necessário definir com precisão **quem entra no estudo**. Critérios mal definidos geram viés de seleção que compromete tanto o treinamento quanto a validade clínica dos resultados.

2.1 Critérios de Inclusão

- **Primeira internação em UTI** (evitar correlação entre internações repetidas do mesmo paciente)
- Permanência na UTI ≥ 48 horas (tempo mínimo para haver histórico suficiente + desfecho mensurável)
- Idade ≥ 18 anos
- Pelo menos **uma medição de hemoglobina** registrada durante a internação em UTI
- Disponibilidade de dados no sistema Metavision (CareVue tem estrutura diferente — tratar separado ou excluir)

2.2 Critérios de Exclusão

- **Pacientes cirúrgicos com sangramento ativo intraoperatório** — confundimento extremo, transfusão quase sempre mandatória
- Testemunhas de Jeová ou recusa documentada de hemotransfusão
- Dados faltantes **>60% nas primeiras 24h** (indicativo de registro ruim, não de dado clínico)
- Internações com menos de **3 medições de hemoglobina** (insuficiente para série temporal de Hb)

2.3 Tamanho esperado da coorte

Critério	Pacientes (aproximado)
MIMIC-III total	61.532 internações, ~46k pacientes únicos
Após filtro: 1ª UTI + ≥48h + adultos	~35.000–40.000 internações
Após filtro: ≥1 medição de Hb	~28.000–33.000
Após exclusões clínicas	~20.000–25.000 internações úteis

Decisão de Desfecho

Opção A — Mortalidade em 28 dias: Desfecho binário claro. Y_{target} = sobrevivência. Problema: mortalidade em UTI é multifatorial; o sinal de transfusão fica diluído. A VCIP precisará de τ longo (7+ dias = muitos passos).

Opção B — Variáveis clínicas proxy (recomendada para VCIP): Y_{target} = vetor [Hb ≥ 7.5, PAM ≥ 65, lactato ≤ 2.0, SpO2 ≥ 94]. Horizonte τ = 4–24h. Mais interpretável, sinal mais imediato e controlável.

Opção C — Composta: Usar variável clínica como Y_t (sinal de treinamento) e mortalidade como métrica de validação externa. Recomendada como estratégia final.

ETAPA 3

Pré-Processamento: Time Grid de 5 Minutos

Alinhar dados heterogêneos em grade temporal regular

O MIMIC é um banco de eventos — cada medição tem timestamp próprio. O VCIP, como qualquer modelo de série temporal supervisionado, requer dados em uma **grade temporal regular**. O time grid de 5 minutos é adequado para UTI: capta variações hemodinâmicas rápidas sem criar esparsidade excessiva.

3.1 Estratégia de Time Grid

Referência zero ($t=0$): Horário de admissão na UTI (INTIME do ICUSTAYS). Todos os timestamps são convertidos para **minutos desde admissão**, depois divididos por 5 para gerar o índice do slot.

Pseudocódigo de alinhamento temporal

```
# Para cada evento com timestamp ts:
slot = floor((ts - icu_intime).total_seconds() / 300)
# 300 segundos = 5 minutos
```

```
# Manter apenas slots dentro de [0, max_stay_slots]
```

3.2 Regras de Agregação por Slot

Quando múltiplas medições caem no mesmo slot de 5 min, aplicar:

Tipo de variável	Regra de agregação	Justificativa
Sinais vitais contínuos (FC, PA, SpO2)	Média do slot	Reduz ruído pontual de artefatos
Hemoglobina / exames laboratoriais	Último valor do slot	Exames não mudam intraslot; usar mais recente
Tratamentos / intervenções (transfusão)	Max (presença) ou soma (dose)	Conservador: se houve transfusão no slot, At=1
Débito urinário	Soma do slot	Volume acumulado no período
Scores clínicos (SOFA, GCS)	Último valor disponível	Scores são calculados, não amostrados

3.3 Imputação de Dados Faltantes

Um slot sem medição não significa "ausência clínica" — significa que o valor não foi registrado. Estratégias por tipo:

- **Forward fill (LOCF):** Para sinais vitais e labs — carregar o último valor observado. Válido porque valores clínicos não mudam abruptamente entre medições.
- **Backward fill limitado:** Aplicar apenas nas primeiras 2h de admissão, onde dados podem ser retrospectivos.
- **Imputação por mediana da coorte:** Para missing inicial (antes da 1ª medição). Estratificar por tipo de UTI (cirúrgica vs. clínica).
- **Missing indicator:** Criar feature binária `xvar_missing_t` = 1 quando o valor foi imputado. O modelo aprende a distinguir dados observados de imputados.
- **Máximo de imputação contínua:** Não fazer forward fill por mais de **4 horas (48 slots)** — após esse tempo, tratar como dado estruturalmente faltante e considerar excluir o período.

Esta é a etapa de maior impacto no desempenho clínico do modelo. As features devem capturar o estado fisiológico do paciente de forma completa, sem redundância excessiva, e com granularidade compatível com decisões clínicas reais.

4.1 Sinais Vitais — Grupo A (Xt)

Feature	ITEMID MIMIC (principais)	Justificativa clínica
Frequência cardíaca (bpm)	211, 220045	Taquicardia é compensação de anemia/choque
Pressão arterial média — PAM (mmHg)	456, 220052	Limiar de perfusão: PAM < 65 = hipoperfusão
Pressão arterial sistólica (mmHg)	51, 220179	Indicador de choque hemorrágico
Pressão arterial diastólica (mmHg)	8368, 220180	Componente da PAM
Saturação periférica de O ₂ — SpO2 (%)	646, 220277	Oxigenação tecidual
Frequência respiratória (rpm)	615, 220210	Compensação de acidose / anemia
Temperatura (°C)	678, 223762	Sepse, estado metabólico
GCS — Escala de Coma de Glasgow	198, 220739, 223900, 223901	Estado neurológico; confundimento com sedação

4.2 Exames Laboratoriais — Grupo B (Xt)

Feature	ITEMID (D_LABITEMS)	Justificativa clínica
Hemoglobina (g/dL)	51222	Gatilho primário de transfusão — variável central
Hematócrito (%)	51221	Correlato da Hb; útil como feature redundante
Plaquetas (10 ³ /μL)	51265	Coagulopatia associada — decisão de hemocomponente
INR / RNI	51237	Coagulopatia — indica necessidade de FFP junto à PRBC
Lactato (mmol/L)	50813	Marcador de hipoperfusão — alvo secundário crucial
Creatinina (mg/dL)	50912	Função renal — modula decisão de volume
Bilirrubinas (mg/dL)	50885, 50883	Hemólise, função hepática
Leucócitos (10 ³ /μL)	51301	Estado inflamatório / séptico

Sódio, Potássio (mEq/L)	50983, 50971	Equilíbrio eletrolítico — relevante para suporte
pH arterial / pCO ₂ / pO ₂	50820, 50818, 50821	Gasometria — acidose metabólica por hipoperfusão
Base excess / Bicarbonato	50802, 50803	Estado ácido-base; severidade do choque

4.3 Terapias e Intervenções Concorrentes (Xt e At)

Além da transfusão (nosso **At** principal), outras intervenções são covariáveis importantes pois influenciam tanto a decisão de transfundir quanto os desfechos:

Variável	Fonte	Papel no modelo
Vasopressores (dose de noradrenalina µg/kg/min)	INPUTEVENTS_MV	Covariável Xt: estado de choque vasoplégico
Ventilação mecânica (binário)	PROCEDUREEVENTS_MV	Covariável Xt: gravidade respiratória
Volume de cristalóides (mL/h)	INPUTEVENTS_MV	Covariável Xt: efeito diluição na Hb
Furosemida (mg/h)	INPUTEVENTS_MV	Covariável Xt: balanço hídrico ativo
Transfusão de PRBC (binária/contínua)	PROCEDUREEVENTS_MV	Tratamento At — variável central de intervenção
Transfusão de FFP/plaquetas	PROCEDUREEVENTS_MV	Tratamento At secundário (multivariado)
Heparina / anticoagulação	INPUTEVENTS_MV	Covariável Xt: risco de sangramento

4.4 Escores de Gravidade — Variáveis Estáticas V

Calculados na admissão ou nas primeiras 24h; representam características basais do paciente (componente V do histórico $\tilde{H}t$):

- **SOFA score** (Sequential Organ Failure Assessment) — gravidade multiorgânica. Calculado a partir das features já coletadas.
- **SAPS II** (Simplified Acute Physiology Score) — mortalidade esperada na admissão.
- **Diagnóstico de entrada** — categorias ICD-9 agrupadas: séptico, cirúrgico, trauma, cardíaco, neurológico.
- **Idade, sexo, peso estimado** (de altura e peso registrados).
- **Tipo de UTI** — cirúrgica (SICU), médica (MICU), cardíaca (CCU), coronariana (CSRU).

4.5 Feature Engineering Temporal — Derivadas

Além dos valores brutos, features derivadas ao longo do tempo carregam informação clínica valiosa sobre **tendências e velocidade de mudança**:

- **Δ Hemoglobina (30min, 2h, 6h):** Taxa de queda de Hb — indica velocidade do sangramento ativo. Ex.: $\Delta Hb(6h) = Hb(t) - Hb(t-72\text{slots})$
- **Rolling mean (janela de 1h e 4h):** Para FC, PAM e SpO2 — suaviza artefatos e captura tendência de estabilidade
- **Rolling std (janela de 1h):** Variabilidade de FC e PA — alta variabilidade indica instabilidade hemodinâmica
- **Tempo desde última transfusão:** Quantos slots atrás o paciente recebeu PRBC — efeito carregado do tratamento
- **Carga cumulativa de vasopressores:** Soma ponderada da dose de noradrenalina nas últimas 4h — proxy de gravidade do choque
- **Balanco hídrico cumulativo (mL):** Input – Output desde admissão — efeito de diluição na Hb observada
- **Hora do dia (seno/cosseno):** Captura ritmo circadiano de coletas e padrões de decisão clínica — codificado como $\sin(2\pi \cdot h/24)$, $\cos(2\pi \cdot h/24)$
- **Dia de internação em UTI:** Pacientes críticos têm padrões diferentes no 1º vs. 3º vs. 7º dia

Vetor final de features por slot

Dimensão estimada de X_t : ~60–80 features por slot de 5 min

Dimensão de V (estáticas): ~15–20 features de admissão

Dimensão de A_t : 1 (binária: transfundiu?) ou 2 (binária + dose em unidades)

Horizonte máximo de histórico: 72h = 864 slots de 5 min (janela de contexto da LSTM)

ETAPA 5

Definição de Desfecho e Estrutura da Amostra de Treinamento

Construir os pares $(\tilde{H}_t, \tilde{a}_t, \tau, Y_{target})$ que alimentam o VCIP

Esta etapa define exatamente como os dados são segmentados para criar as amostras de treinamento. Cada amostra é um par (histórico, sequência de tratamento, desfecho observado) que o VCIP usa para aprender.

5.1 Definição do Desfecho Y_{target}

Recomendamos **abordagem composta em dois níveis**:

- **Desfecho primário de treinamento (variável contínua):** Vetor clínico $[Hb, PAM, Lactato, SpO_2]$ no instante $t+\tau$. O VCIP aprende a otimizar esse vetor.
- **Alvo-meta (para otimização):** $Y_{target} = [Hb \geq 7.5, PAM \geq 65, Lactato \leq 2.0, SpO_2 \geq 94]$ — uma zona-alvo clínica.
- **Validação externa:** Mortalidade em 28 dias — para verificar se sequências ótimas segundo o VCIP se correlacionam com sobrevivência real.

5.2 Janelamento com Rolling Window

Para cada internação de comprimento T slots, gerar múltiplas amostras por **janela deslizante**:

Estrutura de janelamento

```
Para cada internação  $i$  com  $T$  slots:
  Para cada  $t$  de  $[t_{min}, T - \tau - 1]$ :
    histórico =  $X[0:t], A[0:t-1], Y[0:t] \rightarrow H^-_t$ 
    tratamento =  $A[t:t+\tau] \rightarrow \tilde{a}_t, \tau$ 
    alvo =  $Y[t+\tau] \rightarrow Y_{target}$ 
    guardar sample =  $(H^-_t, \tilde{a}_t, \tau, Y_{target})$ 
   $t_{min} = \text{máximo}(48 \text{ slots} = 4h \text{ de histórico mínimo})$ 
```

Parâmetros críticos de janelamento:

- **τ (horizonte):** Testar $\tau \in \{12, 24, 48, 72\} \text{ slots} = \{1h, 2h, 4h, 6h\}$. Começar com $\tau=24$ (2h) — clinicamente relevante para decisão de transfusão
- **Histórico mínimo:** $t_{min} = 48 \text{ slots} (4h)$ — necessário para LSTM ter contexto suficiente
- **Subsampling temporal:** Para reduzir correlação entre amostras da mesma internação, amostrar a cada 12 slots (1h) em vez de cada slot

5.3 Divisão Treino/Validação/Teste

Dividir por **SUBJECT_ID** (paciente), não por internação — evita vazamento de informação de um paciente para seus dados de teste:

Conjunto	Composição
Treino (70%)	~14.000–17.000 pacientes — otimizar ϕ e θ
Validação (15%)	~3.000–4.000 pacientes — tuning de hiperparâmetros e early stopping
Teste (15%)	~3.000–4.000 pacientes — avaliação final, não tocar durante desenvolvimento

Atenção: Viés de Confundimento por Indicação

O problema central: Pacientes mais graves recebem mais transfusões — logo, nos dados observacionais, transfusão parece associada a piores desfechos. Isso é confundimento clássico, não efeito causal.

Como o VCIP endereça: Através do ajuste pela g-fórmula ($\lambda \cdot [\dots]$ no LELBO) e das premissas de ignorabilidade + positividade. É fundamental que TODAS as variáveis de confusão estejam em X_t (escores de gravidade, vasopressores, etc.).

Verificação: Após treinamento, fazer análise de sensibilidade com E-value para quantificar o confundimento residual não medido necessário para anular os achados.

ETAPA 6

Normalização e Preparação de Tensores

Preparar os dados no formato exato exigido pelo VCIP

6.1 Normalização de Features

- **Features contínuas (X_t):** Z-score por feature, calculado APENAS no conjunto de treino. Aplicar média e std do treino ao val/teste. Clipping em $\pm 4\sigma$ para outliers extremos (artefatos de monitoramento).
- **Tratamento binário A_t :** Sem normalização — mantido como 0/1.
- **Tratamento contínuo A_t (unidades de PRBC):** Normalizar por máximo observado no treino (0–1). Alternativamente, discretizar em $\{0, 1, 2, \geq 3\}$ unidades.
- **Features estáticas V :** Z-score para contínuas (idade, peso, scores). One-hot encoding para categóricas (tipo de UTI, diagnóstico). Concatenar ao vetor de entrada da LSTM no instante $t=0$.
- **Desfecho Y_t :** Z-score por componente — o modelo aprende a prever desvios da média da coorte.

6.2 Formato de Tensores para o VCIP

Formato dos tensores de entrada

```
# Por internação, após janelamento:
X:      [N_samples, max_t, dim_x]      # histórico de covariáveis
A:      [N_samples, max_t + tau, 1]    # histórico + sequência futura de  $A_t$ 
Y:      [N_samples, max_t, dim_y]      # histórico de resultados
V:      [N_samples, dim_v]             # features estáticas
Y_target: [N_samples, dim_y]           # alvo  $Y_{target}$  em  $t+\tau$ 
mask:   [N_samples, max_t]             # máscara de padding (0 onde não há dado)

# Valores típicos para este projeto:
```

```

max_t    ≈ 864    (72h a 5min = horizonte máximo de histórico)
tau      = 24     (2h de horizonte de otimização – ajustável)
dim_x    ≈ 70     (features de  $X_t$ )
dim_y    = 4      ([Hb, PAM, Lactato, SpO2])
dim_v    ≈ 20     (features estáticas  $V$ )
dim_a    = 1      (ou 2 se  $A_t$  multivariado)

```

ETAPA 7

Implementação do VCIP

Arquitetura, função de perda e hiperparâmetros

7.1 Estrutura Geral do Código

Recomendamos implementação em **PyTorch** com as seguintes classes principais:

- `HistoryEncoder` — LSTM que processa $\tilde{H}_t$ e produz a distribuição de Z_t
- `TransitionModel` — LSTM que dado Z_s e $\tilde{a}_t, \tau$ produz Z_{s+1}
- `OutcomeDecoder` — MLP que dado $Z_{t+\tau}$ produz $Y_{t+\tau}$
- `InterventionPrior` — LSTM/MLP que modela $p(\tilde{a}_t, \tau \mid \tilde{H}_t)$ e $p(a_s \mid Z_s)$
- `InferenceEncoder` — LSTM que dado $\tilde{H}_t, Y_{t+\tau}, \tilde{a}_t, \tau$ infere $q\phi(\tilde{Z}_t, \tau+1)$
- `VCIPModel` — classe principal que combina todos os componentes e calcula LELBO

7.2 Hiperparâmetros Recomendados para MIMIC

Hiperparâmetro	Valor recomendado	Justificativa
Tamanho do estado latente (dim_z)	32–64	Suficiente para a complexidade do estado clínico; >128 tende a overfit
Hidden size das LSTMs	64–128	Balanceio entre capacidade e regularização
Camadas das LSTMs	2	Profundidade suficiente; 3+ piora gradiente
Hidden size dos MLPs	64–128 com 2 camadas	Decoder e prior são funções mais simples
Dropout	0.2–0.3 (treino)	Regularização; crítico com dados clínicos ruidosos
Batch size	256–512	Grande suficiente para estimativa estável do ELBO

Learning rate	1e-3 (Adam, warm-up 1k steps)	Standard para modelos com ELBO variacional
λ (peso do ajuste de confundimento)	1.0 (começar com 0.5)	Controla a g-fórmula; $\lambda=0$ = ablação sem ajuste
Épocas	100–200 com early stopping	Early stopping por ELBO de validação (paciência 15 épocas)
KL annealing	0→1 nas primeiras 20 épocas	Evita posterior collapse no início do treinamento

7.3 A Função de Perda LELBO para este Problema

Adaptação da Equação 19 do artigo para o contexto clínico com saída multivariada:

Componentes do LELBO para MIMIC

```
# Termo 1: KL divergence (alinhamento inference-generativo)
L_KL = Σ_s KL(qφ(Zs|·) || pθ(Zs|·))

# Termo 2: Reconstrução do desfecho (log-likelihood Gaussiana)
# Y_target é vetor 4D: [Hb, PAM, Lactato, SpO2]
L_rec = -E_q[log pθ(Y_target | Z_{t+τ})]
        = MSE(μy(Z_{t+τ}), Y_target) / σy² + log σy

# Termo 3: Ajuste de confundimento (g-fórmula)
L_conf = λ · (Σ_s E_q[log pθ(as|Zs)] - log pθ(ā|H⁻t))

# Perda total (minimizar)
L_ELBO = β·L_KL + L_rec + λ·L_conf
# β: annealing de 0→1 nas primeiras épocas
```

Considerações para desfecho multivariado

Ponderação das componentes do alvo: Normalizar cada componente de Ytarget pelo seu range clínico antes de calcular a perda. Hb (3–18 g/dL), PAM (40–130 mmHg), Lactato (0.5–15 mmol/L), SpO2 (70–100%). Isso evita que componentes com maior amplitude dominem o gradiente.

Alternativa: Usar perda binária cruzada se Ytarget for discretizado como 'dentro da zona-alvo' (0/1). Simplifica o LELBO mas perde granularidade.

8.1 Protocolo de Treinamento

1. **Pré-treino do encoder de histórico:** Treinar separadamente o LSTM de $H_t \rightarrow Z_t$ como autoencoder para inicializar pesos (opcional, mas acelera convergência)
2. **Treinamento completo do VCIP:** Minimizar LELBO com KL annealing nas primeiras 20 épocas. Monitorar LELBO de validação, L_{KL} , L_{rec} e L_{conf} separadamente
3. **Busca de hiperparâmetros:** Random search com 30 configurações. Critério: LELBO de validação mínimo
4. **Checkpointing:** Salvar modelo a cada 5 épocas; restaurar melhor checkpoint ao final
5. **Gradient clipping:** $max_norm=1.0$ — essencial para LSTMs com sequências longas (864 slots)

8.2 Monitoramento do Treinamento

- **LELBO total:** Deve decrescer monotonicamente (com ruído). Aumento súbito indica instabilidade
- **Razão L_{KL} / L_{rec} :** Se KL domina ($>70\%$ da perda), aumentar β do annealing mais lentamente. Se L_{rec} domina, pode haver posterior collapse
- **Variância das amostras latentes:** Se $var(Z_t) \rightarrow 0$, o modelo está ignorando o encoder de inferência — posterior collapse. Solução: reduzir β ou usar warm-up mais longo
- **L_{conf} :** Deve convergir para valor estável; oscilação grande indica que o prior de intervenção está mal especificado

8.3 Estudo de Ablação

Replicar a Tabela 3 do artigo para o contexto clínico. Comparar 4 versões:

Configuração	λ	KL
VCIP completo	1.0	Sim
VCIP sem ajuste ($\lambda=0$)	0.0	Sim
VCIP sem KL	1.0	Não
Baseline: ACTIN/CRN	—	—

Com o modelo treinado e fixo, a Etapa 9 é o coração da aplicação clínica: dado um novo paciente com histórico H_t , encontrar a sequência ótima de decisões de transfusão nos próximos τ passos.

9.1 Espaço de Busca das Intervenções

Dependendo de como A_t foi definido:

- **At binário (transfundir: sim/não):** Para $\tau=24$ slots (2h), há $2^{24} \approx 16M$ sequências possíveis. Busca exaustiva é inviável; usar **otimização por gradiente com relaxação contínua** ($\text{sigmoid}(\hat{a}_t, \tau) \in [0, 1]$, threshold em 0.5 na inferência)
- **At contínuo (dose em unidades):** Otimização por gradiente direta, com restrição $[0, 4]$ unidades por slot de decisão. Projetar $\hat{a}_t, \tau$ ao domínio válido após cada passo de gradiente

9.2 Algoritmo de Otimização Adaptado ao Problema Clínico

Algorithm 1 — Adaptado para transfusão em UTI

Entrada: H^t (histórico do paciente), Y_{target} (zona clínica-alvo)
modelo VCIP treinado, $\alpha=0.01$, $M=500$ épocas de otimização

```
1. Inicializar  $\bar{a} = \text{zeros}(\tau)$  # sem transfusão como baseline  
    $\bar{a} = \bar{a}.\text{requires\_grad\_}(\text{True})$   
  
2. Para cada época  $m$  de 1 a  $M$ :  
   a.  $\bar{a}_{\text{sig}} = \text{sigmoid}(\bar{a})$  # relaxação contínua de decisão binária  
   b.  $L = \text{VCIP.compute\_LELBO}(H^t, \bar{a}_{\text{sig}}, Y_{\text{target}})$   
   c.  $L.\text{backward}()$  # gradientes de  $L$  em relação a  $\bar{a}$   
   d.  $\bar{a} = \bar{a} - \alpha \cdot \nabla L$  # passo de gradient descent  
   e.  $\bar{a} = \text{clamp}(\bar{a}, -6, 6)$  # estabilidade numérica  
  
3.  $\bar{a}^* = (\text{sigmoid}(\bar{a}) > 0.5).\text{float}()$  # binarizar decisão final  
Saída:  $\bar{a}^*$  = sequência ótima de decisões de transfusão
```

9.3 Restrições Clínicas na Otimização

A otimização matemática pura pode gerar sequências clinicamente absurdas. Implementar **restrições hard** como penalidades na função de perda ou projeções pós-gradiente:

- **Máximo de transfusões consecutivas:** Penalizar sequências com >4 unidades de PRBC em 24h — limites fisiológicos de absorção

- **Intervalo mínimo entre transfusões:** Forçar intervalo $\geq 2h$ entre eventos de transfusão (tempo de nadir da resposta a Hb)
- **Positividade:** Verificar se o VCIP está explorando regiões com suporte nos dados — sequências sem precedente clínico não são confiáveis
- **Regularização L1 sobre $\tilde{a}$:** Adicionar $\alpha_{reg} \cdot ||\tilde{a}||_1$ à perda — favorece soluções esparsas (transfundir menos vezes)

ETAPA 10

Métricas de Avaliação e Validação Clínica

Como medir se o VCIP de fato identifica as melhores sequências

10.1 Métricas de Ranking (Avaliação no Dataset Simulado ou Observacional)

Para avaliação no MIMIC (dados observacionais), usa-se a sequência **realmente aplicada** como "ground truth" e candidatos gerados artificialmente. Métricas do artigo:

- **GRP (Ground Truth Ranking Position):** O modelo deve colocar a sequência observada (que gerou o desfecho real) no topo do ranking. GRP próximo de 1 = modelo bom
- **RCS (Ranking Correlation Score):** Correlação de Spearman entre o ranking do modelo e o ranking por distância ao alvo real. Mede se o modelo ordena corretamente *todas* as candidatas, não apenas identifica a melhor

10.2 Métricas de Distância ao Alvo

- **Target Distance Clínica:** Distância L2 normalizada entre o desfecho real sob a sequência ótima e o alvo: $||Y[\tilde{a}^*] - Y_{target}|| / ||Y_{baseline} - Y_{target}||$. Razão < 1 = o VCIP melhora em relação ao baseline de não-transfusão
- **Taxa de Alcance da Zona-Alvo:** Proporção de pacientes cuja sequência ótima $\tilde{a}^*$ resulta em $Y_{t+\tau}$ dentro de Y_{target} . Métrica binária, mais interpretável clinicamente
- **NNT (Number Needed to Treat):** Quantos pacientes precisam receber a sequência ótima para um alcançar a zona-alvo. Métrica de relevância clínica

10.3 Métricas de Segurança e Plausibilidade

- **Taxa de sequências clinicamente plausíveis:** % das $\tilde{a}^*$ geradas que respeitam as restrições clínicas definidas na Etapa 9
- **Concordância com guideline:** Comparar decisão do VCIP (transfundir/não) com a regra de Hb < 7 g/dL. Investigar casos de discordância — são os mais informativos
- **Distribuição de timing das transfusões:** Histograma de 'quando' o VCIP sugere transfundir vs. prática observada. Desvios sistemáticos = aprendizado de padrão clínico novo

10.4 Validação Causal Indireta

Como os contrafactuais são inobserváveis no MIMIC (diferente do dataset tumoral simulado), a validação causal deve ser indireta:

- **Análise de subgrupos conhecidos:** Em pacientes cirúrgicos com sangramento ativo, o VCIP deve sugerir mais transfusões que em pacientes sépticos estáveis — valida se o modelo aprendeu heterogeneidade clínica
- **E-value para confundimento residual:** Calcular o E-value das estimativas do modelo — quantifica quanto confundimento não medido seria necessário para anular os resultados
- **Placebo test:** Embaralhar aleatoriamente os tratamentos At e retreinar — o modelo não deve aprender padrão significativo (verificação de que o sinal é causal, não espúrio)
- **Correlação com mortalidade:** Verificar se pacientes cuja sequência observada se aproxima da sequência ótima do VCIP têm menor mortalidade. Análise observacional com ajuste de confundimento

Comparação de Modelos Baseline

RMSN: Recurrent Marginal Structural Network — baseline mais relevante para séries temporais com confundimento

CRN: Counterfactual Recurrent Network — LSTM com reversão de gradiente para balanceamento

CT (Causal Transformer): Versão com Transformer — importante se τ longo ($>24h$) onde LSTM pode ter limitações

ACTIN: Dual-module — melhor tradeoff eficiência/eficácia reportado no artigo

Regra clínica simples: "Transfundir se $Hb < 7$ g/dL" — baseline clínico interpretável e juridicamente defensável

Sumário Executivo do Pipeline

Nº	Etapa	Saída Principal	Ferramentas
1	Acesso e estrutura MIMIC	Tabelas SQL extraídas	BigQuery / PostgreSQL + psycopg2
2	Seleção de coorte	Lista de ICUSTAY_IDs válidos (~20k)	SQL + pandas
3	Time grid 5 min + imputação	DataFrame: [paciente $\times$ slot $\times$ feature]	pandas, numpy
4	Feature engineering	Tensor X_t (~70 features), At , Y_t , V	pandas, scipy, sklearn

5	Estrutura de amostras	Dataset: ($\hat{H}_t$, $\hat{a}_t, \tau$, Y_{target}) por janela	<code>torch.Dataset</code> customizado
6	Normalização + tensores	Tensores PyTorch prontos para treino	<code>sklearn.StandardScaler</code> , <code>torch</code>
7	Implementação VCIP	Classes LSTM/MLP + função LELBO	<code>PyTorch</code> , <code>Lightning</code> (opcional)
8	Treinamento + ablação	Modelos treinados + curvas de validação	<code>PyTorch</code> , <code>W&B</code> ou <code>MLflow</code>
9	Otimização de $\bar{a}^*$	Sequência ótima por paciente	<code>PyTorch autograd</code> , <code>scipy.optimize</code>
10	Métricas + validação	GRP, RCS, target distance, correlação	<code>scikit-learn</code> , <code>lifelines</code> , <code>seaborn</code>

Pipeline VCIP × MIMIC-III para Decisão de Transfusão em UTI

Baseado em Wang et al. (ICML 2025) — "Variational Counterfactual Intervention Planning to Achieve Target Outcomes"